

# **Обзор основных методов обучения искусственного интеллекта**

Зиберов А.А.

**Постановка задачи:** обучение искусственного интеллекта является актуальным направлением современной науки, так как это открывает множество новых возможностей в отраслях экономики, медицины, промышленности и других. Также, при должном развитии и обучении, ИИ позволяет решать многие задачи намного быстрее и точнее человека, что тоже является значительным преимуществом. **Цель работы:** рассмотреть методы обучения искусственного интеллекта. **Используемые методы:** метод анализа, метод сравнения. **Результат:** приведена характеристика, достоинства, недостатки и практические способы применения каждого метода обучения. **Ключевые слова:** искусственный интеллект, машинное обучение.

## **Актуальность исследований**

Исследования на тему методов обучения искусственного интеллекта (ИИ) являются крайне важными, так как помогают улучшить существующие методы и создать новые. Также, они позволяют расширять границы возможностей ИИ и делать его более эффективным и точным в решении самых разных задач.

## **Введение**

Искусственный интеллект стал универсальным термином для приложений, которые выполняют сложные задачи, которые когда-то требовали участия человека. В связи с быстрым развитием компьютеров и доступностью больших данных, появилось много новых методов для обучения ИИ, каждый из которых имеет свои преимущества и недостатки. Некоторые методы подходят лучше для определенных типов данных и задач, а другие – для более общих. В статье рассмотрены каждый из существующих на сегодняшний день способов обучения.

## Основная часть

Суть обучения искусственного интеллекта (ИИ) заключается в создании алгоритмов, которые могут учиться на основе опыта и данных без явно заданной программной инструкции. Это позволяет ИИ адаптироваться к новым ситуациям и решать различные задачи самостоятельно. Важно различать понятия искусственного интеллекта и модель ИИ. ИИ — это общее понятие, которое охватывает все системы, способные к умственной деятельности, в то время как модель ИИ — это конкретная реализация алгоритма, результат тренировки ИИ для определенной задачи. Например, модель искусственного интеллекта может быть создана для распознавания лиц на изображениях, и она может использовать глубокое обучение и нейронную сеть для достижения высокой точности распознавания.

Выделяют следующие разновидности обучения ИИ:

- а) обучение с учителем;
- б) обучение без учителя;
- в) обучение с частичным привлечением учителя;
- г) обучение с подкреплением.

Рассмотрим подробнее приведенные методы обучения:

Обучение с учителем (англ. Supervised learning) — один из способов машинного обучения, в ходе которого испытуемая система принудительно обучается с помощью примеров «стимул-реакция» (вопрос-ответ). Данный способ предполагает наличие полного набора размеченных данных для тренировки модели на всех этапах ее построения. Размеченные данные — это данные, дополненные метками/классами, содержащими значимую информацию, например: изображения с меткой «кошка»/«собака», электронные письма/письма с пометкой спам, аудиофайлы с информацией о словах в них и так далее. В процессе обучения ИИ строит модель, которая может использоваться для предсказания результатов для новых данных. В

основном обучение с учителем применяется для решения двух типов задач: классификации и регрессии.

Задача классификации состоит в предсказании какой-либо категории из ограниченного набора.

Пусть  $X$  – множество описаний объектов,  $Y$  – конечное множество номеров (имен, меток) классов. Существует неизвестная целевая зависимость – отображение  $y^*: X \rightarrow Y$ , значения которой известны только на конечной обучающей выборке  $X^m = (x_1, y_1), \dots, (x_m, y_m)$ . Требуется построить алгоритм  $a: X \rightarrow Y$ , способный классифицировать произвольный объект  $x \in X$ . Например, изображены ли на фото кот или собака, является ли голос на аудиозаписи мужским или женским и т.д. Методы классификации часто применяются для распознавания образов или речи, а также находят применение в медицине, маркетинге и сфере финансов.

Задачи регрессии же связаны с непрерывными данными. Существует 7 типов методов регрессии: линейная, логистическая, гребенчатая, лассо, полиномиальная и байесовская. Среди них линейная и байесовская регрессии являются наиболее используемыми и популярными методами машинного обучения.

Рассмотрим линейную регрессию. Данный алгоритм вычисляет ожидаемое значение переменной  $y$ , учитывая конкретные значения  $x$ . Поскольку линейная регрессия выявляет линейную зависимость, она определяет, как изменяется значение зависимой переменной при изменении значения независимой. Связь между переменными представлена наклонной прямой линией в модели линейной регрессии (рисунок 1).



Рисунок 1 – Схема линейной регрессии

Суть обучения ИИ при помощи линейной регрессии заключается в нахождении оптимальных весов для каждой переменной на основе минимизации суммы квадратов отклонений модели от фактических значений и оценке ее точности. После обучения модели ИИ этим методом на наборе исходных данных, можно сделать прогноз будущих значений, оценить корреляцию переменных, а также классифицировать данные (например, является ли объект продуктом высокого или низкого качества на основе его характеристик). Такие модели используются для анализа данных и прогнозирования результатов.

Достоинства:

- высокая точность предсказания: модель обучается на метках, что позволяет соотносить предсказываемые ответы с настоящими;
- можно обрабатывать неструктурированные данные: данные с известными метками могут иметь различную структуру, в том числе текстовые, аудио- и видеофайлы;
- быстрота обучения: благодаря использованию меток, модель может быстрее сходиться к оптимальным значениям весов.

Недостатки:

- затратная процедура разметки данных: создание набора данных с известными метками может быть затратным и трудоемким процессом;
- неустойчивость к шумам в данных: модель может слишком сосредоточиться на мелких деталях, что может привести к ухудшению ее обобщающей способности.
- ограниченность в использовании нескольких меток: иногда набор данных может иметь только некоторые метки, что усложняет процесс обучения.

Обучение без учителя (Unsupervised Learning) – метод, при котором модель обучается на неразмеченных данных и у модели нет явных указаний как работать с этим набором данных. Модель пытается самостоятельно найти корреляции в данных, извлекая полезные признаки и анализируя их.

Обучение без учителя решает 2 типа задач: задача кластеризации и задача поиска ассоциативных правил.

Кластеризация – группировка похожих объектов в один кластер на основе их сходства между собой.

Пусть  $X$  – множество описаний объектов,  $Y$  – множество идентификаторов (меток) кластеров. На множестве  $X$  задана функция расстояния между объектами  $\rho(x, x')$ . Дана конечная обучающая выборка объектов  $X^m = \{x_1, \dots, x_m\} \subset X$ . Необходимо разбить выборку на подмножества (кластеры), то есть каждому объекту  $x^i \in X^m$  сопоставить метку  $y^i \in Y$ , таким образом, чтобы объекты внутри каждого кластера были близки относительно метрики  $\rho$ , а объекты из разных кластеров значительно различались. Следовательно, алгоритм кластеризации представляет собой функцию  $a: X \rightarrow Y$ , которая любому объекту  $x \in X$  ставит в соответствие идентификатор кластера  $y \in Y$ .

Существуют методы кластеризации: К-средних, DBSCAN, иерархическая кластеризация и кластеризация на основе плотности графа. В качестве примера рассмотрим алгоритм К-средних.

Алгоритм k-средних (k-means) наиболее простой, но в то же время достаточно неточный метод кластеризации в классической реализации. Он разбивает множество элементов векторного пространства на заранее известное число кластеров  $k$ . Алгоритм стремится минимизировать среднеквадратичное отклонение на точках каждого кластера. Основная идея заключается в том, что на каждой итерации перевычисляется центр масс для каждого кластера, полученного на предыдущем шаге, затем векторы разбиваются на кластеры вновь в соответствии с тем, какой из новых центров оказался ближе по выбранной метрике. Алгоритм завершается, когда на какой-то итерации не происходит изменения кластеров.

Поиск похожих изображений на основе их содержания является одним из примеров использования кластеризации в фото распознавании. Например, популярная поисковая система Яндекс использует кластеризацию для группировки изображений, которые похожи друг на друга внешне. Алгоритм кластеризации может быть также использован и для того, чтобы создать группы похожих изображений. На основе этого можно решить задачу поиска похожих изображений. Если имеется большой набор фотографий, можно разбить его на группы по теме или по характеристикам изображения (например, на портреты людей и пейзажи). После этого можно применить алгоритм поиска изображений в соответствующих группах. На рисунке 2 представлен пример результата кластеризации изображений алгоритмом DeepCluster, работающим на основе метода k-средних.

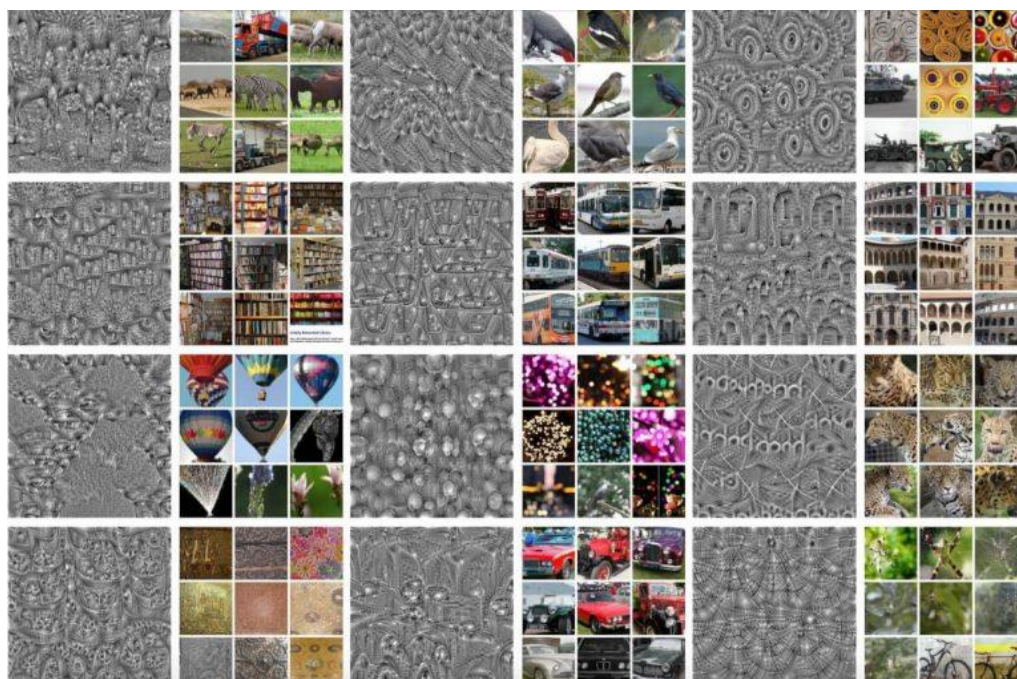


Рисунок 2 – Результат кластеризации изображений при помощи DeepCluster

Задача поиска ассоциативных правил – задача машинного обучения, которая используется для поиска взаимосвязей между переменными в больших наборах данных. Она заключается в выявлении частых комбинаций элементов в наборе данных, называемых «правилами», и представляет собой простой, но мощный метод анализа данных в различных областях, таких как маркетинг, медицина, телекоммуникации и другие. Основным применением задачи поиска ассоциативных правил является улучшение понимания потребительского поведения и выявление закономерностей, связанных с конкретными продуктами или услугами, таким образом, стимулируя более эффективное управление ресурсами и увеличение прибыли. В результате анализа данных на основе задачи поиска ассоциативных правил могут быть выявлены полезные инсайты, которые могут быть использованы для улучшения бизнес-процессов и оптимизации работы компаний.

Достоинства:

- обработка неструктурированных данных: обучение без учителя может работать с неструктурированными данными, такими как тексты, изображения, аудио и видео;

- нет необходимости в метках: для обучения без учителя нет необходимости использовать метки, что снижает затраты на подготовку данных;

- умение находить скрытые структуры: модель может находить скрытые структуры и зависимости в данных, которые могут не быть явными для человека.

Недостатки:

- низкая точность предсказания: поскольку обучение без учителя не использует метки, точность предсказания может быть ниже, чем при обучении с учителем;

- невозможность проверить точность: поскольку данные не имеют известных меток, нет способа проверить точность модели;

- риск обнаружения случайностей: модель может обнаруживать случайные закономерности в данных, которые не несут смысла и не имеют практического применения.

Обучение с частичным привлечением учителя (англ. semi-supervised learning) — разновидность обучения с учителем, которое помимо размеченных данных для обучения также использует неразмеченные данные — обычно в сравнительно большем количестве, чем размеченные.

Главным преимуществом данного метода является возможность работать с очень большими неразмеченными наборами данных, которые были бы сложны для обработки при использовании методов обучения с учителем, однако есть и недостаток — требуется экспертное знание в предметной области, чтобы определить наилучший способ комбинирования неразмеченных и размеченных данных.



Обучение с подкреплением (англ. reinforcement learning) — один из способов машинного обучения, в ходе которого испытуемая система (агент) обучается, взаимодействуя с некоторой средой. Полуавтоматическое обучение отличается от контролируемого, где используются только размеченные данные. Идея заключается в том, что агент взаимодействует со средой, параллельно обучаясь, а целью является вознаградить машину, когда она учится правильно, и наказать, если нет (рисунок 3).




Рисунок 3 – Схема обучения ИИ с подкреплением

Окружение – это среда или объект, на который воздействует Агент (например игра), в то время как Агент представляет собой алгоритм ОП. Процесс начинается с того, что Окружение отправляет свое начальное состояние (state =  $s$ ) Агенту, который затем, на основании своих значений, предпринимает действие (action =  $a$ ) в ответ на это состояние. После чего Окружение отправляет Агенту новое состояние (state' =  $s'$ ) и награду (reward =  $r$ ) Агент обновит свои знания наградой, возвращенной окружением, за последнее действие и цикл повторится. Цикл повторяется до тех пор, пока Окружение не отправит признак конца эпизода.

Обучение с подкреплением применяется там, где нужно соизмерить цель с ситуативным принятием решения. Этот вид обучения решает сложную задачу соотнесения немедленных действий с отсроченной отдачей, которую они производят. Как и людям, алгоритмам подкрепления обучения иногда приходится ждать, чтобы увидеть необходимый результат.

Области практического применения:

- системы восприятия;
- боты для компьютерных игр;
- трейдинговые боты;
- чат боты, которые учатся от диалога к диалогу.

Достоинства:

- адаптивность: агент может адаптироваться к изменениям в окружающей среде и улучшать свое поведение с течением времени;
- самообучение: агент может учиться без участия людей, что позволяет заниматься обучением в автономном режиме;
- адаптивный поиск решений: агент может принимать решения в зависимости от ситуации и условий, используя свой опыт прошлых действий;

Недостатки:

- сложность задачи: задача обучения агента может быть слишком сложной, что может затруднить построение эффективного алгоритма обучения;
- необходимость определения системы вознаграждения: агент должен понимать, какие действия приводят к наилучшему результату, что может быть сложно в задачах, где награды не являются очевидными;
- возможность заикливания: агент может заиклиться и застрять в неправильном решении, если ему не удастся достичь оптимального результата.

Глубокое обучение (англ. Deep learning) — совокупность методов машинного обучения, включающая в себя вышеупомянутые методы. Данный вид обучения тесно связан с нейронными сетями. Нейронные сети — алгоритмы, которые работают по принципу имитации работы человеческого мозга. Базовая нейронная сеть содержит три слоя взаимосвязанных искусственных нейронов: входной слой — обрабатывают данные, анализируют

или классифицируют их и передают на следующий слой, скрытый слой – анализирует выходные данные от входного или других слоев и выходной слой – дает окончательный результат обработки всех данных (может иметь один или несколько узлов).

Обучение глубоких нейронных сетей — сложный процесс, который требует большого количества данных и вычислительных ресурсов. Они имеют несколько скрытых слоев с миллионами связанных друг с другом искусственных нейронов. Число, называемое весом, указывает на связи одного узла с другими. Вес является положительным числом, если один узел возбуждает другой, или отрицательным, если один узел подавляет другой. Узлы с более высокими значениями веса имеют большее влияние на другие узлы. Теоретически глубокие нейронные сети могут сопоставлять любой тип ввода с любым типом вывода, но стоит учитывать, что им требуется гораздо более сложное обучение, чем другим методам машинного обучения. Таким узлам нужны миллионы примеров данных, а не сотни или тысячи, как с простыми сетями. Процесс обучения нейросети в виде схемы изображен на рисунке 4.

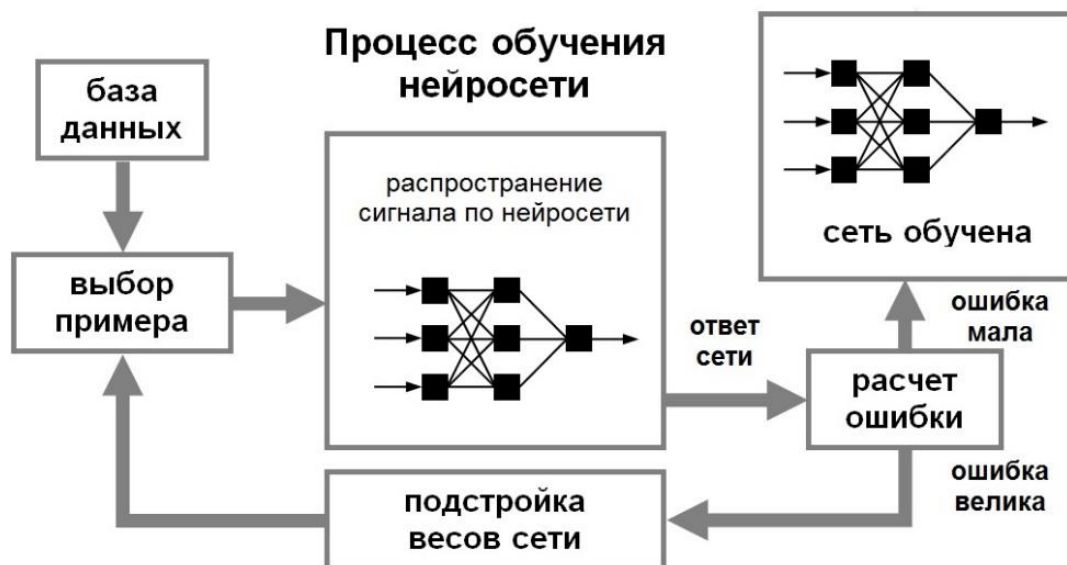


Рисунок 4 – Процесс обучения нейронных сетей

Краткая характеристика методов обучения глубоких нейронных сетей:

1. Обучение с помощью обратного распространения ошибки (backpropagation): самый часто используемый метод обучения глубоких нейронных сетей. Этот метод заключается в том, чтобы постепенно настраивать веса и смещения нейронной сети на основе вычисления градиента функции ошибки.

2. Обучение на основе градиентного спуска (gradient descent): это метод, используемый для оптимизации параметров нейронной сети. Метод состоит в том, чтобы итеративно корректировать веса и смещения нейронной сети, двигаясь по направлению наискорейшего убывания функции ошибки.

3. Обучение с помощью сверхмалых глубинных сетей (shallow network pretraining): это метод, используемый для улучшения сходимости обучения глубоких нейронных сетей. Существует несколько вариантов этого метода, но общая идея заключается в том, чтобы предварительно обучить несколько небольших составляющих глубокой нейронной сети и затем объединить их в одну общую сеть.

4. Обучение с помощью алгоритмов генетической оптимизации (genetic algorithms): это метод, используемый для настройки параметров нейронной сети путем эволюции популяции нейронных сетей.

Глубинное обучение широко используется в распознавании изображений и речи, обработке и генерации текстов, рекомендательных системах, управлении беспилотными автомобилями.

Достоинства:

- широкие возможности обучения с работой исключительно в нужном направлении развития нейронных сетей;
- низкая чувствительность к шумам: метод способен эффективно работать с данными, в которых присутствуют шумы или искажения;
- способность работать в режиме реального времени: даже на больших объемах данных Deep Learning способен быстро обрабатывать информацию.

### Недостатки:

- высокая требовательность к вычислительным ресурсам: для входных данных с большим количеством признаков и слоями для обработки данных требуется большое количество вычислительной мощности;
- необходимость большого количества данных для обучения модели: для получения точных и стабильных результатов метод Deep Learning требует большого объема данных для обучения.

### Выводы

В данной статье рассмотрены основные методы обучения искусственного интеллекта, выявлены их достоинства и недостатки, а также раскрыты сферы их применения. Исследование показало, что наиболее перспективным методом обучения, несмотря на имеющиеся недостатки, является метод глубокого обучения Deep Learning, но следует отметить, что в некоторых задачах другие методы могут быть более эффективными и подходящими.

## СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Искусственный интеллект и Машинное обучение. Основы программирования на Python / Т. Казанцев — «ЛитРес: Самиздат», 2020
2. Машинное обучение простыми словами — URL: <https://newtechaudit.ru/mashinnoe-buchenie/>
3. AI/ML : типы обучения — URL: <https://evogeek.ru/articles/30116/>
4. Обучение нейросети с учителем, без учителя, с подкреплением — в чем отличие? — URL: <https://neurohive.io/ru/osnovy-data-science/obuchenie-s-uchitelem-bez-uchitelja-s-podkrepleniem/>
5. Задача классификации (Classification problem) — URL: <https://wiki.loginom.ru/articles/classification-problem.html>
6. Обучение без учителя (Unsupervised Learning) — URL: <https://www.helenkapatsa.ru/niekontroliruiemoie-obuchieniie/>
7. Кластеризация: алгоритмы k-means и c-means — URL: <https://habr.com/ru/articles/67078/>
8. Deep Cluster — алгоритм глубокой кластеризации — URL: <https://neurohive.io/ru/papers/deep-cluster/>
9. Введение в различные алгоритмы обучения с подкреплением (Q-Learning, SARSA, DQN, DDPG) — URL: <https://habr.com/en/articles/561746/>
10. Созыкин А.В. Обзор методов обучения глубоких нейронных сетей // Вестник ЮУрГУ. Серия: Вычислительная математика и информатика. 2017. Т. 6, № 3. С. 28–59. DOI: 10.14529/cmse170303.
11. Как работает Deep Learning? — URL: <https://proglib.io/p/deep-learning>